

如何知道 Agent 变好了还是变坏了

LLM-as-judge · Golden Dataset · Regression Suite · CI/CD 质量门控

三种 EVAL 方法

LLM-AS-JUDGE

让 AI 评判 AI

- ✓ 能评主观质量（开放式输出）
- ✓ 比人工快 100x，可扩展
- ✗ judge 本身有偏见
- ✗ 每次有 API 成本（用 Haiku）

适用：开放式QA / 内容生成

GOLDEN DATASET

黄金数据集

- ✓ 完全可重复，零 API 成本
- ✓ 精确捕捉回归退化
- ✗ 构建成本高（100条需数天）
- ✗ 格式变化时测试易失效

适用：工具调用 / Safety规则


REGRESSION SUITE

版本对比回归

- ✓ 无需期望值，检测相对退化
- ✓ 模型升级的最佳护航工具
- ✗ 需要维护 baseline 版本
- ✗ 退化阈值设定需要经验

适用：模型升级 / 重构回归

三维度评分



加权：Quality 50% + Latency 25% + Cost 25%

CI 集成流程



核心洞察

ANTHROPIC 2026-01-09

"Evals 是开发进程
是否正确的仪器"

EVALS 穿插原则

每章末尾有小 eval
不能等到最后才做

成本控制铁律

judge 用 Haiku
边界区才升 Sonnet

TTS 反向验证案例

TTS → ASR → 相似度
< 0.4 自动重试
8-bit 比 4-bit 快 2.3x

VERIFICATION_AGENT

CC 内置实时 eval
TodoWriteTool.ts:107

LENA V1.7 COMPOSITE SCORES

Quality 0.82 · Latency 0.73 · Cost 0.77 →

Composite 0.78 [GOOD]

ANTHROPIC DEMYSTIFYING EVALS · 2026-01-09

"跑完没报错 ≠ 质量合格" · [anthropic.com/engineering](#)

© 从零构建你的 AI Agent · Ch 17